

Phân loại kết quả học tập của sinh viên UIT

1st Phạm Văn Duy

Khoa Khoa học và Kỹ thuật Thông tin
Trường Đại học Công nghệ Thông tin
Hồ Chí Minh, Việt Nam
22520341@gmail.uit.edu.vn

2nd Trương Hoài Bảo

Khoa Khoa học và Kỹ thuật Thông tin
Trường Đại học Công nghệ Thông tin
Hồ Chí Minh, Việt Nam
22520126@gmail.uit.edu.vn

3rd Nguyễn Võ Tiến Lộc

Khoa Khoa học và Kỹ thuật Thông tin
Trường Đại học Công nghệ Thông tin
Hồ Chí Minh, Việt Nam
22520792@gmail.uit.edu.vn

Tóm tắt nội dung—Trong bài báo cáo này, chúng tôi trình bày một phương pháp phân loại kết quả học tập của sinh viên tại Trường Đại học Công nghệ Thông tin (UIT) [1]. Dữ liệu được xử lý qua các bước tiền xử lý và sử dụng các mô hình học máy để phân tích và dự đoán. Sau quá trình thực nghiệm cho thấy XGBoost là mô hình cho kết quả tốt nhất với F1-macro lên đến 73%.

Từ khóa: Học máy, phân loại kết quả học tập, kỹ thuật smote, Trường Đại học Công nghệ Thông tin

I. GIỚI THIỆU TỔNG QUAN

Giáo dục, tiêu chí thứ 4 trong 17 mục tiêu phát triển bền vững của Liên Hợp Quốc [2], đóng vai trò quan trọng trong sự phát triển xã hội và nâng cao chất lượng cuộc sống. Trong đó, giáo dục đại học được xem là một trong những yếu tố then chốt, không chỉ cung cấp tri thức chuyên sâu mà còn phát triển các kỹ năng tư duy phản biện, năng lực sáng tạo và khả năng thích nghi trước những biến động của thế giới hiện đại. Đồng thời, giáo dục đại học cũng góp phần quan trọng vào việc thúc đẩy đổi mới, nâng cao năng suất lao động và xây dựng nguồn nhân lực chất lượng cao cho xã hội.

Kết quả học tập ở bậc đại học không chỉ phản ánh trình độ chuyên môn mà còn thể hiện sự kiên trì, ý chí và nỗ lực của sinh viên trong quá trình học tập và phát triển bản thân. Xếp loại tốt nghiệp, vì thế, trở thành một tiêu chí quan trọng để đánh giá năng lực cá nhân và tiềm năng nghề nghiệp trong tương lai. Tuy nhiên, ở Việt Nam, vẫn tồn tại không ít trường hợp sinh viên gặp khó khăn trong học tập hoặc thậm chí bỏ học giữa chừng [3]. Việc phát hiện sớm và can thiệp kịp thời trong những trường hợp này là vô cùng cần thiết để giúp sinh viên vượt qua thách thức, tiếp tục học tập và hoàn thiện bản thân.

Trong bối cảnh công nghệ số hóa phát triển mạnh mẽ, lĩnh vực khai phá dữ liệu giáo dục (Educational Data Mining - EDM) đã nổi lên như một công cụ hiệu quả, cho phép phân tích dữ liệu phức tạp và trích xuất thông tin giá trị về hành vi học tập cũng như kết quả học tập của sinh viên. Đặc biệt, việc áp dụng các thuật toán học máy trong dự đoán kết quả học tập không chỉ giúp nhà trường và giảng viên đưa ra các biện pháp hỗ trợ kịp thời mà còn nâng cao chất lượng giáo dục thông qua tối ưu hóa quy trình giảng dạy và quản lý sinh viên.

Báo cáo này, chúng tôi áp dụng các thuật toán học máy, bao gồm Random Forest, Support Vector Machine(SVM), Logistic Regression và XGBoost, nhằm phân loại kết quả học tập của

sinh viên tại Trường Đại học Công nghệ Thông tin (UIT), TP. Hồ Chí Minh. Mục tiêu của báo cáo là hỗ trợ giảng viên cố vấn học tập trong việc theo dõi tiến độ học tập và can thiệp sớm đối với sinh viên có nguy cơ gặp khó khăn. Ngoài ra, nhóm nghiên cứu còn phát triển một nền tảng website thân thiện với người dùng, hỗ trợ giảng viên dễ dàng truy cập và đánh giá dữ liệu học tập của sinh viên.

Các đóng góp chính của báo cáo:

- Ứng dụng các thuật toán học máy kết hợp với phương pháp SMOTE [4] để phân loại kết quả học tập của sinh viên.
- Phát triển nền tảng website hỗ trợ giảng viên trong việc giám sát và đánh giá tiến trình học tập của sinh viên.

Cấu trúc của bài báo như sau: Phần 1 giới thiệu tổng quan báo cáo. Phần 2 trình bày các nghiên cứu liên quan. Phần 3 mô tả phương pháp và quy trình thực hiện. Phần 4 tập trung vào kịch bản thực nghiệm. Các kết quả báo cáo được trình bày trong Phần 5. Phần 6 và Phần 7 lần lượt đề cập đến nền tảng website, các thách thức và hướng phát triển. Cuối cùng, Phần 8 trình bày kết luận.

II. CÁC CÔNG TRÌNH LIÊN QUAN

Trong một thống kê năm 2024 cho thấy, đối với dữ liệu giáo dục 88% các nghiên cứu tận dụng các thuật toán Machine Learning như **decision trees, support vector machines, random forests, and logistic regression** trong việc dự đoán, phân loại các kết quả học tập [5]. Các nghiên cứu trong lĩnh vực dữ liệu giáo dục thường chia ra theo các trường hợp ứng dụng như là dự đoán kết quả học tập, xác định các sinh viên có nguy cơ bỏ học, hệ thống phân tích hỗ trợ giảng viên.

Gần đây nhất trong năm 2024, nghiên cứu nhằm dự đoán sớm các sinh viên có nguy cơ bỏ học và các sinh viên có khả năng đạt loại xuất sắc [6] sử dụng bộ dataset từ nguồn University of California, Irvine (UCI) machine learning repository [7] có 4424 dòng dữ liệu, với cách tiếp cận stacking [8] mô hình Random Forest và LightGBM cho hiệu suất 79,2% trên thang đo F1-weighted [9]. Năm 2021, một nghiên cứu [10] sử dụng các thuật toán liên quan học kết hợp (Ensemble learning) như Adaboost, Extremely Gradient Boosting để thực hiện phân loại kết quả học tập trên tập dữ liệu 497 mẫu cho ra kết quả accuracy 0.95 tuy nhiên trên độ đo F1 vẫn đạt mức khiêm tốn 66.67%. Năm 2019, "An Efficient Approach for Multiclass Student Performance Prediction based upon Machine Learning" [11] bài nghiên cứu này được thực hiện với mục đích phân loại 3 lớp "poor", "average", "good", nhóm tác giả sử dụng các

mô hình như Decision Tree, Random Forest, Gradient Boost, Extreme Gradient Boost tối ưu hóa độ chính xác phân lớp lên đến 95%. Trong bài phân loại đa nhãn "Grade prediction of student academic performance with multiple classification models", 2018 [12], nhóm nghiên cứu đã đạt được chỉ số ấn tượng với 65.90% accuracy trên tập huấn luyện và 62.04% accuracy trên tập kiểm tra. Các mô hình học máy Naive Bayes, Decision Tree, Multilayer Perceptron and Support Vector được dùng để phân loại và đánh giá trong trường hợp này.

Nhìn chung các nghiên cứu liên quan dữ liệu giáo dục thường được làm trên tập dữ liệu nhỏ, điều này cũng khá dễ hiểu vì đó là thông tin cá nhân nhạy cảm của mỗi người trong suốt quá trình học tập. Dựa trên động lực này trong quá trình xử lý dữ liệu nhóm cố gắng kiểm tra và giữ lại số dòng dữ liệu nhiều nhất có thể. Ngoài ra, một trong những vấn đề của bài toán phân loại kết quả học tập này là các nền giáo dục khác nhau có những hệ thống điểm số khác nhau, văn hóa cách tiếp cận cũng khác nên việc tạo ra một mô hình phổ quát chung cho tất cả các nền giáo dục nhìn chung có nhiều thách thức.

III. PHƯƠNG PHÁP

Quá trình thực hiện bài toán này trải qua 3 giai đoạn chính **Hình 1**. Đầu tiên là thu thập tiền xử lý dữ liệu, thực hiện qui trình kiểm tra gán nhãn. Thứ hai, nhóm thực hiện qui trình huấn luyện và đánh giá mô hình thực hiện k-fold (StratifiedK-Fold) [13] cross validation với k=5. Cuối cùng nhóm cung cấp nền tảng website với các tính năng thân thiện người dùng.

A. Định nghĩa dữ liệu đầu vào và đầu ra

Nhóm thực hiện bài toán trên nhằm mục đích phân loại kết quả học tập của sinh viên sau quá trình học đại học với 4 nhãn dữ liệu gồm nhãn 0, 1, 2, 3 tương ứng loại (Giỏi, Xuất sắc), Khá, (Trung Bình Khá, Trung Bình), Chưa đạt.

Dữ liệu đầu vào: các thông tin cá nhân của sinh viên (Ngành học, phương thức xét tuyển,...) và các thông tin về điểm trung bình, điểm rèn luyện học kì trải dài từ năm 1, năm 2, năm 3 hoặc 3.5 năm.


Dữ liệu đầu ra: nhãn 0,1,2,3 tương ứng với giá trị dự đoán.

B. Chuẩn bị dữ liệu

Trong báo cáo này nhóm sử dụng bộ dữ liệu của sinh viên của Trường Đại học Công nghệ thông tin [1]. Bộ dữ liệu gồm 16 files chứa các thông tin về lịch sử học tập, các hoạt động liên quan như các cảnh báo kỉ luật, tình hình nộp bằng anh văn,... Về tính riêng tư của dữ liệu, tất cả thông tin liên quan về cá nhân đã được mã hóa bảo đảm quyền riêng tư và bộ dữ liệu trên chỉ được dùng cho nghiên cứu, học tập.

Bộ dữ liệu từ nguồn thực tế nên sẽ có nhiều thách thức cần được giải quyết. Một là, bộ dữ liệu được lấy từ nhiều phòng ban khác nhau không phải từ một cơ sở dữ liệu quan hệ nên sẽ gây ra nhiều khó khăn trong quá trình kiểm tra. Hai là, có rất nhiều dữ liệu bị thiếu tính nhất quán giữa các bảng giữ liệu cần kiểm tra một cách kĩ lưỡng. Ba là, các nhãn dữ liệu bị mất cân bằng ảnh hưởng đến hiệu suất của mô hình. Cuối cùng, các qui định của trường thay đổi qua từng năm cũng là một thách thức đặt ra cho quá trình tiền xử lý dữ liệu.

C. Tiền xử lý dữ liệu



Hình 2. Luồng xử lý để chọn ra các sinh viên đủ tiêu chuẩn


Quá trình xử lý dữ liệu được diễn ra cẩn thận và chi tiết, được mô tả qua **Hình 2**. Từ các nguồn dữ liệu ban đầu thông qua quá trình tìm hiểu và đánh giá nhóm quyết định chọn các files sau để đưa vào bài toán: sinhviendtbhocky.xlsx, drl.xlsx, diemrl.xlsx, sinhviendtbtoankhoa.xlsx, Thisinh.xlsx. Các files còn lại được dùng để kiểm tra đánh giá các các files chính đưa vào bài toán.

Đối với files **sinhviendtbhocky.xlsx** với mỗi dòng là thông tin cụ thể của một sinh viên, mỗi sinh viên học nhiều kì nên mã số của mỗi sinh viên được xuất hiện nhiều lần trong phần này dữ liệu được loại bỏ các dòng dữ liệu bất thường, xóa bỏ dòng dữ liệu chứa số tín chỉ lớn hơn 30 hoặc với học kì 3 (học kì hè) mà số tín chỉ lớn hơn 12.

Đầu tiên, số sinh viên xuất hiện trong file dữ liệu 13574 sinh viên, nhóm nghiên cứu mong muốn kết hợp với thông tin cá nhân và thông tin về điểm số để phân loại, nên nhóm lọc ra những sinh viên có mã số trong file sinhvien.xlsx. Có 8231 sinh viên còn lại phục vụ cho quá trình kiểm tra.

Tiếp theo, nhóm lọc ra các bạn sinh viên học từ 6 kì chính trở lên, vì ít nhất cần 6 kì để hoàn thành chương trình học tại trường, sau khi thực hiện bước này chỉ còn 7267 thỏa mãn điều kiện. Tại phần này nhóm chia dữ liệu thành hai phần, nhóm sinh viên có xuất hiện trong file tốt nghiệp và nhóm còn lại, số lượng mẫu nhận được tương ứng là **1831** sinh viên, 5346 sinh viên.

Bước thứ 3, 5346 sinh viên còn lại có **3141** đã tiêu chuẩn về số tín chỉ tối thiểu để tốt nghiệp. 2259 sinh viên còn lại nếu sinh viên nào học từ 6 năm trở lên sẽ được gán cho nhãn là chưa đạt **324**. Số sinh viên đạt chuẩn theo hướng này là **5296**. Sau khi kết hợp files về dữ liệu điểm trung bình từng kì và file điểm



Hình 1. Hình ảnh tổng quan phương pháp tiếp cận bài toán

rèn luyện sinh viên nhóm nhận được số mẫu cuối cùng là **5181** dòng dữ liệu.

Có 2 files **drl.xlsx**, **diemrl.xlsx** nhưng giống nhau về cấu trúc nên tiến hành gộp cả 2 và xóa bỏ đi 2 cột id và ghi chú để đảm bảo tính nhất quán. Cột drl có nhiều giá trị null do bị trùng lặp ở toàn bộ cột (trừ cột drl) nên tiến hành xóa những dòng giống nhau về mssv, namhoc, hocky nhưng drl có giá trị null trong dữ liệu.

File **ThiSinh.xlsx** chứa các thông tin về cá nhân, phương thức xét tuyển ('THPT', 'TT-Bộ', 'CUTUYEN', 'UT-Bộ', '30A', 'UT-ĐHQG', 'ĐGNL', 'CCQT'), nhóm tiền hàng one-hot encoding thành 5 nhóm chính là 'THPT', 'ĐGNL', 'UT-Bộ', 'UT-ĐHQG' và nhóm còn lại, dựa trên tính chất của phương thức xét tuyển.

Do giới hạn về số trang của bài nghiên cứu nên nhóm thực hiện chi tiết quá trình tìm hiểu và phân tích dữ liệu tại đường dẫn liên kết sau [14]. Quá trình tiền xử lý bao gồm việc loại bỏ dữ liệu thiếu, mã hóa các giá trị phân loại, và chuẩn hóa dữ liệu số.

D. Chiến lược gán nhãn

Sử dụng dữ liệu về điểm trung bình toàn khóa trên file **sinhvientbtoankhoa.xlsx** để gán nhãn theo quy định. Vì loại sinh viên không chỉ phụ thuộc vào điểm số mà còn phụ thuộc

Bảng I
BẢNG XẾP LOẠI VÀ THANG ĐIỂM TƯƠNG ỨNG [15]

Loại	Thang điểm 10	Thang điểm 100	Điểm 4	Điểm chữ	Xếp loại
Đạt	9,0 đến 10,0	Từ 90 đến 100	4,0	A+	Xuất sắc
	8,0 đến cận 9,0	Từ 80 đến cận 90	3,5	A	Giỏi
	7,0 đến cận 8,0	Từ 70 đến cận 80	3,0	B+	Khá
	6,0 đến cận 7,0	Từ 60 đến cận 70	2,5	B	Trung bình khá
	5,0 đến cận 6,0	Từ 50 đến cận 60	2,0	C	Trung bình
Không đạt	4,0 đến cận 5,0	Từ 40 đến cận 50	1,5	D+	Yếu
	3,0 đến cận 4,0	Từ 30 đến cận 40	1,0	D	Kém
	<3,0	Dưới 30	0,0	F	Kém

vào yếu tố khác như điểm rèn luyện,. Nhóm thực hiện bước tiếp theo là ánh xạ loại tốt nghiệp của sinh viên trong file **totnghiep.xlsx** sang, đồng thời các sinh viên học trên 6 năm thuộc nhóm nhân chưa đạt ở bước xử lý trước đều được gán nhãn chưa đạt.

Nhóm thực hiện kiểm tra lại xem các sinh viên được gán nhãn loại giỏi và xuất sắc thì rèn luyện của họ có bị vượt dưới mức trung bình hay không, đối với sinh viên xuất sắc là dưới 75 sẽ hạ bậc tốt nghiệp, con số này là 65 đối với sinh viên xếp loại giỏi [15]. Kết quả kiểm tra cho thấy các sinh viên giỏi, xuất sắc đều đảm bảo điểm rèn luyện ở mức đạt.


Về việc kiểm tra số tín chỉ học lại, nhóm nhận thấy rằng so với quy định hiện hành nếu sinh viên học lại trên 5 phần trăm

thì sẽ bị hạ loại tốt nghiệp, tuy nhiên trong các sinh viên xuất sắc không sinh viên nào bị rơi vào trường hợp này [16].

Bảng II
THỐNG KÊ SỐ LƯỢNG NHÂN BAN ĐẦU

Lớp	Sau khi gộp nhân	Giải thích
0	28	Xuất sắc
1	1252	Giỏi
2	2645	Khá
3	908	Trung Bình Khá
4	25	Trung bình
5	323	Chưa đạt
Tổng cộng	5181	Các nhân

Nhóm quyết định gộp nhân để số lượng mẫu các lớp được hợp lí hơn, mục tiêu của bài toán là hỗ trợ cố vấn học tập trong công tác cố vấn nên nhóm cần chú ý là nhóm chưa đạt, các nhóm sinh viên còn lại có mức điểm tương tự nhau thì được gom vào một nhóm là một lựa chọn hợp lí.



Hình 3. Biểu đồ phân phối số lượng sinh viên theo các nhóm nhân dữ liệu.

E. Phương pháp học máy

Trong bài nghiên cứu này, chúng tôi sử dụng các mô hình học máy phổ biến trong phân tích dữ liệu giáo dục, sử dụng các tài nguyên của thư viện Scikit-Learn [17] để triển khai mô hình:

- **Random Forest (RF):** Kết hợp nhiều cây quyết định để tăng độ chính xác và duy trì tính dễ hiểu, phù hợp với bài toán phức tạp.
- **Support Vector Machine (SVM):** Tìm mặt siêu phẳng để phân loại dữ liệu, thường dùng trong phân loại và hồi quy.
- **XGBoost:** Một thuật toán tăng cường gradient mạnh mẽ, tối ưu hóa hiệu suất, hỗ trợ xử lý dữ liệu lớn và giảm overfitting.
- **Logistic Regression (LR):** Dựa trên hàm logistic để phân loại và tìm mối liên kết giữa các biến dữ liệu.

F. Thông số đánh giá

Để đánh giá hiệu quả mô hình, nhóm sử dụng các độ đo phổ biến như F1-Score, Recall, Precision và Accuracy, với cách tính trung bình macro [9].

Precision và Recall cho lớp k trong bài toán phân loại K lớp được định nghĩa:

$$\text{Precision}_k = \frac{TP_k}{TP_k + FP_k}, \quad \text{Recall}_k = \frac{TP_k}{TP_k + FN_k}$$

Trong đó: TP_k : mẫu đúng lớp k , FP_k : mẫu sai nhầm vào k , FN_k : Số mẫu thuộc lớp k nhưng dự đoán sai thành lớp khác.

Các giá trị trung bình macro:

$$\text{MacroPrec} = \frac{1}{K} \sum_{k=1}^K \text{Precision}_k, \quad \text{MacroRec} = \frac{1}{K} \sum_{k=1}^K \text{Recall}_k$$

$$\text{Macro F1-Score} = 2 \cdot \frac{\text{MacroPrec} \cdot \text{MacroRec}}{\text{MacroPrec} + \text{MacroRec}}$$

Trong các bài toán dữ liệu không cân bằng, Accuracy có thể không phản ánh đúng hiệu suất mô hình. F1-Score, trung bình điều hòa giữa Precision và Recall, phù hợp hơn khi cân bằng giữa độ chính xác và khả năng phát hiện lớp hiếm. Macro F1-Score còn giúp đánh giá toàn diện bằng cách không bị ảnh hưởng bởi sự chênh lệch tần suất giữa các lớp.

IV. THỰC NGHIỆM

A. Các kịch bản thực nghiệm

Sau khi dữ liệu được làm sạch và kết nối các files liên quan lại với nhau nhóm được bộ dữ liệu cuối cùng với các trường dữ liệu sau, về lí lịch sinh viên Bảng III.

Bảng III
CÁC CỘT DỮ LIỆU LIÊN QUAN ĐẾN THÔNG TIN CÁ NHÂN CỦA SINH VIÊN

Tên cột	Giải thích
mssv	Mã số sinh viên
diem_tt	Điểm trúng tuyển
Phương thức xét tuyển	Giải thích
OTHER, THPT, ĐGNL	Các phương thức xét tuyển khác, THPT, Đánh giá năng lực
UT-Bộ, UT-ĐHQG	Các phương thức xét tuyển ưu tiên Bộ và ĐHQG
Hệ đào tạo	Giải thích
hedt_CLC, hedt_CNTN, hedt_CQUI	Các hệ đào tạo chất lượng cao, cử nhân tài năng, chính qui
hedt_CTTT, hedt_KSTN	Hệ đào tạo chương trình tiên tiến và kỹ sư tài năng
Mã ngành	Giải thích
7340122_CLC, 7340122_CQ	Thương mại điện tử
7480101_CLC, 7480101_CQ	Khoa học máy tính
7480101_CTTN	Khoa học máy tính chương trình tài năng
7480102_CLC, 7480102_CQ	Mạng máy tính và truyền thông
7480103_CLC, 7480103_CQ	Công nghệ phần mềm
7480104_CLC, 7480104_CQ, 7480104_CTTT	Hệ thống thông tin
7480106_CLC, 7480106_CQ	Kỹ thuật máy tính
7480109_CQ	Khoa học dữ liệu
7480201_CLC, 7480201_CQ	Công nghệ thông tin
7480202_CLC, 7480202_CQ, 7480202_CTTN	An toàn thông tin

Các thông tin về chuyên ngành, hệ đào tạo, phương thức xét tuyển sẽ được one-hot encoding, đối với điểm trúng tuyển sẽ được Min-Max scaling. Trường hợp sinh viên tham gia xét tuyển bằng phương thức OTHER thì diem_tt được hệ thống trường cho là -1.

Nhóm thực hiện quá trình thực nghiệm trên các trường hợp như sau để đo kết quả dự đoán. Dự đoán với lần lượt đầu vào của dữ liệu là thông tin ghi nhận cho đến năm 1 năm, 2 năm, 3 năm, 3.5 năm, cụ thể dữ liệu đầu vào của các mô hình lần lượt:

Bảng IV
CÁC TRƯỜNG DỮ LIỆU ĐẦU VÀO ĐỂ HUẤN LUYỆN MÔ HÌNH.

Số năm	Các trường dữ liệu đầu vào
1 năm	sem1, sem2, sem3, term 1, term 2
2 năm	sem1, sem2, sem3, sem4, sem5, sem6, term 1, term 2, term 3, term 4
3 năm	sem1, sem2, sem3, sem4, sem5, sem6, sem7, sem8, term 1, term 2, term 3, term 4, term 5, term 6
3.5 năm	sem1, sem2, sem3, sem4, sem5, sem6, sem7, sem8, sem9, sem10, term 1, term 2, term 3, term 4, term 5, term 6, term 7

Trong đó, mỗi năm có kì 1, 2, hệ điểm trung bình học kì sẽ có dạng "sem*". Điểm rèn luyện trong một năm sẽ có điểm của 2 kì chính "term*". Các giá trị cũng sẽ được min-max scaling, trường hợp sinh viên không học trong kì thì sẽ được điền là -1.

Khi thực nghiệm, ứng với từng năm để làm dữ liệu đầu vào dự đoán, nhóm kết hợp thông tin về cá nhân làm gốc, dữ liệu điểm số thay đổi ở số kì nên có sự khác nhau.

Quá trình thực nghiệm, chúng tôi sử dụng Stratified K-Fold Cross-Validation với k=5 để đánh giá hiệu suất mô hình. Phương pháp này đảm bảo rằng tập dữ liệu được chia thành 5 phần (fold) sao cho tỷ lệ các lớp trong mỗi fold giống với tỷ lệ của toàn bộ tập dữ liệu. Sử dụng thực nghiệm trên google colab. Thực hiện kĩ thuật SMOTE: Synthetic Minority Over-sampling Technique [4] để tăng nhân lớp nhân hiếm, smote dữ liệu huấn luyện trong mỗi fold đảm bảo tập kiểm tra mỗi fold là dữ liệu thực tế.

B. Cấu hình mô hình

Chúng tôi sử dụng GridSearchCV [18] để tìm ra bộ siêu tham số, kết hợp với việc tinh chỉnh thủ công cuối cùng chúng tôi chọn ra được bộ siêu tham số tối ưu với từng mô hình như sau.

Bảng V
BẢNG MÔ TẢ CẤU HÌNH CHẠY THỰC NGHIỆM.

Model	Parameter Configuration
SVM	C: 1.0, Kernel: 'linear', Max_Iter: 5000
Random Forest	n_estimators: 100, max_depth: None, random_state: 42
Logistic Regression	Penalty: 'l1', C: 10, Solver: 'saga', Max_Iter: 1000, Multi_Class: 'multinomial', Random_State: 42
XGBoost	Learning_Rate: 0.1, n_Estimators: 100, Max_Depth: 6, Random_State: 42, Objective: 'multi:softmax', Eval_Metric: 'mlogloss'

V. KẾT QUẢ

A. So sánh hiệu quả của mô hình phân loại trước khi SMOTE

Sau khi chạy thực nghiệm các mô hình học máy, nhóm thu được bảng kết quả như sau:

Bảng VI
HIỆU SUẤT CÁC MÔ HÌNH TRÊN THANG ĐO MACRO F1 VÀ RECALL (REC)

	1 năm		2 năm		3 năm		3.5 năm	
	f1	rec	f1	rec	f1	rec	f1	rec
LR	0.5237	0.5117	0.6064	0.5942	0.6789	0.6583	0.7096	0.6895
SVM	0.4817	0.4821	0.5646	0.5738	0.6498	0.6433	0.7085	0.6920
RF	0.5477	0.5282	0.6388	0.6217	0.6935	0.6707	0.7206	0.6967
XGBoost	0.5540	0.5345	0.6453	0.6306	0.7079	0.6922	0.7315	0.7173

Qua bảng kết quả thực nghiệm ta thấy rằng, các mô hình học máy có chỉ số f1 tăng theo từng năm cho thấy rằng với càng nhiều dữ liệu đầu vào thì khả năng dự đoán của mô hình càng tăng. Chỉ số f1, recall của mô hình XGBoost chiếm ưu thế so với các mô hình còn lại qua các trường hợp thực nghiệm khác nhau cho thấy đây là một giải pháp tối ưu trong trường hợp này.

Do việc mất cân bằng dữ liệu nên khi đo với độ đo macro, kết quả cho ra không giống như kì vọng.

Bảng VII
VÍ DỤ MINH HỌA KẾT QUẢ CỦA FOLD 4 CHO TỪNG NHÂN ĐỐI VỚI TRƯỜNG HỢP CỦA XGBOOST 3.5 NĂM

Class	Fold 4 F1	Fold 4 Rec	Fold 4 Precision
Nhân 0	0.92	0.93	0.91
Nhân 1	0.88	0.88	0.87
Nhân 2	0.70	0.72	0.69
Nhân 3	0.50	0.42	0.61

Vì giới hạn số trang nhóm chỉ lấy 1 fold cao nhất trong 5 fold để làm minh họa. Chúng ta nhận thấy rằng, việc dữ liệu mất cân bằng ảnh hưởng rất lớn đối với hiệu suất tổng quan của mô hình khi nhân 3 luôn có chỉ số đo lường thấp hơn hẳn so với các nhân còn lại. Đây là lí do vì sao mô hình cho ra các kết quả chưa đến 80%.

B. Kết quả dự đoán sau khi sử dụng SMOTE [4]

Bảng VIII
HIỆU SUẤT CÁC MÔ HÌNH TRÊN THANG ĐO MACRO F1 VÀ RECALL (REC)

	Năm 1		Năm 2		Năm 3		Năm 3.5	
	f1	rec	f1	rec	f1	rec	f1	rec
LR	0.5556	0.6108	0.6475	0.6934	0.6897	0.7259	0.7254	0.7634
SVM	0.5445	0.5996	0.6326	0.6873	0.6899	0.7354	0.7315	0.7748
RF	0.5666	0.5798	0.6647	0.6734	0.7257	0.7309	0.7525	0.7552
XGBoost	0.5654	0.5908	0.6569	0.6748	0.7144	0.7276	0.7453	0.7579

Ta thấy rằng sau khi sử dụng kĩ thuật SMOTE để làm cân bằng mẫu huấn luyện thì các chỉ số f1, recall đều được cải thiện ở tất cả các mô hình. Trước khi cân bằng nhân, **XGBoost** chiếm ưu thế so với tất cả mô hình còn lại, nhưng sau khi sử dụng SMOTE **Random Forest** vượt lên với chỉ số các độ đo f1 ngang ngửa so với **XGBoost**. Vì bài toán nhằm giúp cố vấn học tập có

thể hỗ trợ nhiều sinh viên nhiều nhất có thể nên chúng ta chấp nhận đánh đổi ưu tiên độ đo Recall. Do đó lựa chọn mô hình tối ưu cho bài toán này của nhóm nghiên cứu là **XGBoost**, Bảng VIII.

Bảng IX
SO SÁNH ĐỘ ĐO TRƯỚC VÀ SAU KHI THỰC HIỆN SMOTE ĐỐI VỚI XGBOOST

	Trước SMOTE			Sau SMOTE		
	Precision	Recall	F1-Score	Precision	Recall	F1-Score
1 năm	0.6155	0.5345	0.5540	0.5523	0.5908	0.5654
2 năm	0.6801	0.6306	0.6453	0.6452	0.6748	0.6569
3 năm	0.7430	0.6922	0.7079	0.7053	0.7276	0.7144
3.5 năm	0.7580	0.7173	0.7315	0.7361	0.7579	0.7453

Sau khi thực hiện smote ta thấy kết quả các độ đo được cải thiện, các kết quả về recall cũng được cải thiện.

VI. GIỚI THIỆU WEBSITE

Sau quá trình huấn luyện, đánh giá tinh chỉnh mô hình nhóm tiến hành xây dựng website để hỗ trợ cố vấn học tập trong việc quản lí. Về phía giao diện, Reactjs [19] là công nghệ được lựa chọn vì nó là một framework phổ biến và dễ dàng tiếp cận. Với Backend, nhóm sử dụng ExpressJS [20] và Python để làm các hàm xử lí tương tác và tương tác với model. Các tính năng của website như là đăng nhập, xem danh sách lớp, xem chi tiết thông tin sinh viên. Video demo và chi tiết website tại [14].

VII. THÁCH THỨC VÀ HƯỚNG PHÁT TRIỂN

Thách thức: đây là bộ dữ liệu thực tế nên gặp rất nhiều khó khăn trong quá trình xử lí dữ liệu. Quá trình gán nhãn được diễn ra một cách nghiêm ngặt tuyệt đối, tuy nhiên việc các files có giá trị thiếu quá nhiều nên trong quá trình xử lí cũng còn một số mặt hạn chế.

Hướng phát triển: Ứng dụng các thuật toán Deep learning trong quá trình phân loại dữ liệu để kiểm tra độ hiệu quả, thử nghiệm kiểm tra cách tiếp cận kết hợp dữ liệu thông tin sinh viên(tabular) và điểm qua thời gian học(timeseries) theo mô hình nghiên cứu của nhóm tác giả đi trước để kiểm tra độ hiểu quả [21]. Thực hiện làm giàu dữ liệu hơn với CTGAN [22].

VIII. KẾT LUẬN

Qua báo cáo, chúng tôi đã hoàn thành một qui trình học máy hiệu quả trong phân loại kết quả học tập của sinh viên.

Chúng tôi cung cấp một nền tảng website thân thiện với người dùng giúp cho quá trình cố vấn của giảng viên chủ nhiệm được thuận tiện hơn.

TÀI LIỆU

[1] T. CNTT, “Trang chủ trường đại học công nghệ thông tin,” 2024. [Online]. Available: <https://www.uit.edu.vn/>

[2] U. Nations, “Ensure inclusive and equitable quality education and promote lifelong learning opportunities for all,” 2024. [Online]. Available: <https://sdgs.un.org/goals/goal4>

[3] B. thanh niên, “Tìm giải pháp để sinh viên không bỏ học,” 2024. [Online]. Available: <https://thanhnien.vn/tim-giai-phap-de-sinh-vien-khong-bo-hoc-185241031202606105.htm>

[4] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, “Smote: Synthetic minority over-sampling technique,” *Journal of Artificial Intelligence Research*, vol. 16, pp. 321–357, 2002.

[5] Z. Ersozlu, S. Taheri, and I. Koch, “A review of machine learning methods used for educational data,” *Education and Information Technologies*, pp. 1–21, 2024.

[6] T. R. Noviandy, Z. Zahriah, E. Yandri, Z. Jalil, M. Yusuf, N. I. S. M. Yusof, A. Lala, and R. Idroes, “Machine learning for early detection of dropout risks and academic excellence: A stacked classifier approach,” *Journal of Educational Management and Learning*, vol. 2, no. 1, pp. 28–34, 2024.

[7] V. M. M. J. Realinho, Valentim and L. Baptista, “Predict Students’ Dropout and Academic Success,” UCI Machine Learning Repository, 2021, DOI: <https://doi.org/10.24432/C5MC89>.

[8] B. Pavlyshenko, “Using stacking approaches for machine learning models,” in *2018 IEEE Second International Conference on Data Stream Mining Processing (DSMP)*, 2018, pp. 255–258.

[9] M. Grandini, E. Bagli, and G. Visani, “Metrics for multi-class classification: an overview,” 2020. [Online]. Available: <https://arxiv.org/abs/2008.05756>

[10] T. Lenin and N. Chandrasekaran, “Learning from imbalanced educational data using ensemble machine learning algorithms,” *Webology*, vol. 18, no. SI01, pp. 183–195, 2021.

[11] M. F. Al-Hammouri, Z. A. A. Hammouri, I. T. Almalkawi, and A. Lafee, “Optimizing multi-class classification in educational data with ensemble learning and data balancing techniques,” in *2024 Fifth International Conference on Intelligent Data Science Technologies and Applications (IDSTA)*, 2024, pp. 12–17.

[12] X. Zhang, R. Xue, B. Liu, W. Lu, and Y. Zhang, “Grade prediction of student academic performance with multiple classification models,” in *2018 14th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery (ICNC-FSKD)*, 2018, pp. 1086–1090.

[13] Scikit-learn, “StratifiedKFold function sklearn,” 2024. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html

[14] T. N.V.T.Lộc, P.V.Duy, “Tài liệu kĩ thuật,” *UIT*, 2024. [Online]. Available: https://drive.google.com/drive/folders/1pDL1pxGxajrvRtiTIM94MFCZ3SCmc-r_?usp=sharing

[15] Trang web trường đại học Công nghệ thông tin-ĐHQG HCM, “Eda process,” *UIT*, 2024. [Online]. Available: https://daa.uit.edu.vn/sites/daa/files/202309/790-qd-dhcntt_28-9-22_quy_che_dao_tao.pdf

[16] Website trường đại học Công nghệ thông tin, “Graduation rule,” *UIT*, pp. 26–27, 2024. [Online]. Available: https://student.uit.edu.vn/sites/daa/files/202309/790-qd-dhcntt_28-9-22_quy_che_dao_tao.pdf

[17] ScikitLearn, “Thư viện scikit learn,” 2024. [Online]. Available: <https://scikit-learn.org/stable/index.html>

[18] ScikitLearn, “Gridsearchcv,” 2024. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

[19] FaceBook, “Reactjs framework,” 2024. [Online]. Available: <https://react.dev/>

[20] T. Holowaychuk, “Expressjs,” 2024. [Online]. Available: <https://expressjs.com/>

[21] H. Prabowo, A. A. Hidayat, T. W. Cenggoro, R. Rahutomo, K. Purwandari, and B. Pardamean, “Aggregating time series and tabular data in deep learning model for university students’ gpa prediction,” *IEEE Access*, vol. PP, pp. 1–1, 2021.

[22] L. Xu, M. Skoularidou, A. Cuesta-Infante, and K. Veeramachaneni, “Modeling tabular data using conditional gan,” 2019. [Online]. Available: <https://arxiv.org/abs/1907.00503>

STT	MSSV	Họ và Tên	Công việc	Tỉ lệ
1	22520341	Phạm Văn Duy	• Xử lý dữ liệu. • Lập trình backend cho website. • Kiểm duyệt nội dung báo cáo. • Tham gia quá trình tinh chỉnh, huấn luyện mô hình.	32%
2	22520126	Trương Hoài Bảo	• Xử lý dữ liệu. • Lập trình giao diện website. • Làm slide. • Kiểm duyệt nội dung báo cáo. • Tham gia thiết kế sơ đồ.	33%
3	22520792	Nguyễn Võ Tiến Lộc	• Xử lý dữ liệu. • Huấn luyện và đánh giá mô hình. • Chuẩn bị nội dung cho các công trình liên quan. • Thiết kế sơ đồ. • Viết báo cáo.	35%